

BIG DATA

Predicción de Exposición y Vulnerabilidad en Edificaciones ante Ondas Sísmicas mediante Imágenes Geo Satelitales, Topografía del Suelo y Big Data


TEAM:

- Quiliche chavez Andres
- Vergara Marcos Eduardo Coli
- Jehu Salazar Irrazabal
- Tucto Magiliano Chayna



INTRODUCTION

1. Perú está sobre la subducción de la placa de Nazca bajo la Sudamericana (7–8 cm/año). El IGP registra unos 800 sismos sentidos al año.
2. Lima Metropolitana tiene 10.4 millones de habitantes. En el sismo M 6.1 de junio de 2025 se llegó a 251 cm/s^2 en Villa María del Triunfo.



1. El suelo y la topografía amplifican las ondas de forma desigual. Las alertas actuales (SASPe, 106 estaciones) no indican exposición ni daño por edificación.
1. Propuesta: un sistema en Apache Spark con Machine Learning que clasifica la exposición y vulnerabilidad en bajo, medio o alto. Usa imágenes geo satelitales, topografía del suelo (V_s30) y registros de PGA.

A.- AUTOMATIC IDENTIFICATION OF RESIDENTIAL BUILDING FEATURES USING MACHINE LEARNING TECHNIQUES (CARPANESE ET AL., 2023)

PROBLEMA

Evaluar la vulnerabilidad sísmica de edificaciones exige conocer sus características constructivas. Recopilar esos datos con inspecciones de campo toma mucho tiempo y dinero, sobre todo a gran escala (el estudio se enmarca en Italia). Por eso los autores buscan identificar esas características automáticamente a partir de imágenes.



DATABASE


- **Imágenes satelitales:** para ubicar los edificios.
- **Imágenes de Google Street View:** para ver las características visibles de cada edificio.
- **Tipo de edificios:** residenciales.

Table 1. Splitting of the images into training, evaluation and validation for the 3 features.

Feature	Labels	Training (70%)	Validation (15%)	Evaluation (15%)	Total (100%)
Height	Low-Rise	4,004	856	856	10,000
	Mid-Rise	2,998	643	643	
Material	Masonry	4,906	1,051	1,051	10,000
	R.C.	2,094	449	449	
Construction period	Pre-1919	1,621	348	348	10,000
	1919-1945	510	109	109	
	1946-1960	2,056	440	440	
	1961-1980	1,826	391	391	
	Post-1980	989	211	211	

TÉCNICAS

- **Visión por computadora:** extrae información de las imágenes.
- **Redes neuronales convolucionales (CNN):** reconocen las características del edificio.
- **Extracción automatizada:** convierte lo visual en atributos para evaluar vulnerabilidad.



A.- AUTOMATIC IDENTIFICATION OF RESIDENTIAL BUILDING FEATURES USING MACHINE LEARNING TECHNIQUES (CARPANESE ET AL., 2023)

METODOLOGÍA

- 1. **Imágenes satelitales:** se obtiene la ubicación y configuración de los edificios.
- 2. **Street View:** se extraen imágenes de cada edificio.
- 3. **Machine Learning:** se entrenan modelos para reconocer las características de interés, en especial las que afectan la vulnerabilidad sísmica.

RESULTADOS

- Es posible identificar características de edificios de forma remota con ML e imágenes.
- Reduce el tiempo y el costo de las inspecciones presenciales.
- Permite evaluar la vulnerabilidad de muchos más edificios.

Table 2. Precision, recall, and F1-score of the three CNNs.

Feature	Labels	Precision	Recall	F ₁ -score
Height	Low-Rise	0.88	0.91	0.89
	Mid-Rise	0.88	0.83	0.85
Material	Masonry	0.80	0.93	0.86
	R.C.	0.73	0.46	0.57
Construction period	Pre-1919	0.56	0.66	0.61
	1919-1945	0.23	0.05	0.08
	1946-1960	0.61	0.69	0.65
	1961-1980	0.44	0.53	0.48
	Post-1980	0.27	0.11	0.16

B.- ESTIMATION OF PIXEL-LEVEL SEISMIC VULNERABILITY OF THE BUILDING ENVIRONMENT BASED ON MID-RESOLUTION OPTICAL REMOTE SENSING IMAGES (FAN ET AL., 2021)


PROBLEMA

Evaluar la vulnerabilidad sísmica de las edificaciones en áreas extensas es costoso, porque los métodos tradicionales dependen de inspecciones de campo edificio por edificio. Además, interpolar los puntos inspeccionados no capta bien la heterogeneidad del entorno construido. Los autores proponen estimar la vulnerabilidad sísmica a nivel de píxel (PLSV) con imágenes satelitales de resolución media y aprendizaje automático.



DATABASE

- **Zona de estudio:** ciudad de Yancheng (Jiangsu, China).
- **Verdad de terreno:** puntos de investigación de campo repartidos por sus condados.
- **VIIRS:** luces nocturnas.
- **MODIS:** índice de vegetación y reflectancia de superficie.
- **Landsat-8 OLI:** texturas derivadas de la reflectancia.



TÉCNICAS

- **Teledetección multifuente:** VIIRS (actividad humana), MODIS (vegetación) y Landsat-8 (textura del entorno construido).
- **SVR y Random Forest:** relacionan las variables satelitales con la vulnerabilidad observada en campo.
- **Interpolación espacial:** método de referencia para comparar.
- **SIG:** integra las capas en una grilla de píxeles y elabora los mapas.



B.- ESTIMATION OF PIXEL-LEVEL SEISMIC VULNERABILITY OF THE BUILDING ENVIRONMENT BASED ON MID-RESOLUTION OPTICAL REMOTE SENSING IMAGES (FAN ET AL., 2021)


METODOLOGÍA

1. **Vulnerabilidad en campo:** se calcula para las edificaciones inspeccionadas.
2. **Variables por píxel:** luces nocturnas, vegetación, reflectancia y textura.
3. **División de los puntos:** entrenamiento y prueba.
4. **Modelos:** se entrenan SVR y Random Forest para predecir la PLSV.
5. **Comparación:** se contrasta su error con el de la interpolación espacial y se genera el mapa de PLSV de toda la ciudad.



RESULTADOS

- RMSE ≈ 0.1 , mejor que los métodos de interpolación espacial.
- El aprendizaje automático supera a la interpolación.
- La vulnerabilidad del entorno construido se puede mapear a escala urbana con datos satelitales abiertos y pocas inspecciones de campo.



C.- QUAKEFLOW: A SCALABLE MACHINE-LEARNING-BASED EARTHQUAKE MONITORING WORKFLOW WITH CLOUD COMPUTING

PROBLEMA


Las redes sísmicas densas generan volúmenes masivos de datos que los flujos de trabajo convencionales no logran procesar. Para abril de 2022, el archivo sísmico de IRIS ya llegaba a unos 800 TiB, y tecnologías como Distributed Acoustic Sensing aumentan aún más el ritmo de generación de datos.

DATABASE

- **Puerto Rico:** 3 años de registros continuos (mayo 2018 a mayo 2021).
- **Estaciones:** 70 estaciones, unos 210 station-years de datos de tres componentes.
- **Fuentes:** Puerto Rico Seismic Network y redes del USGS.
- **Hawái:** 66 estaciones del Hawaii Volcano Observatory.

TÉCNICAS


- **Apache Kafka:** transmisión distribuida de formas de onda.
- **Spark Streaming:** ETL en tiempo real con ventanas de 30 s.
- **Kubernetes:** escalamiento y procesamiento paralelo en la nube.
- **PhaseNet (CNN):** identifica las fases sísmicas P y S.
- **GaMMA (Gaussian Mixture Model):** asocia fases y estima ubicación y magnitud.



C.- QUAKEFLOW: A SCALABLE MACHINE-LEARNING-BASED EARTHQUAKE MONITORING WORKFLOW WITH CLOUD COMPUTING



METODOLOGÍA

1. **Descarga de datos:** de archivos sísmicos o en tiempo real.
2. **Streaming:** Kafka y Spark Streaming.
3. **Phase picking:** PhaseNet.
4. **Asociación de fases:** GaMMA.
5. **Localización y catálogo:** HypoDD y catálogo de terremotos.



RESULTADOS

- **Puerto Rico:** 143,704 eventos frente a 18,041 del catálogo convencional (7.97 veces más).
- **Hawái:** 81,284 eventos frente a 7,761 (10.47 veces más).
- **Tiempo total:** 3.5 h de descarga, 3 h de PhaseNet y 0.5 h de GaMMA.
- **PhaseNet:** detecta fases con alta precisión y bajo sesgo.



D.- A REAL-TIME AI-ASSISTED SEISMIC MONITORING SYSTEM BASED ON NEW NODAL STATIONS WITH 4G TELEMETRY AND ITS APPLICATION IN THE YANGBI MS 6.4 AFTERSHOCK MONITORING IN SOUTHWEST CHINA


PROBLEMA

- Las redes sísmicas permanentes detectan mal los eventos de baja magnitud.
- Las estaciones nodales no transmiten datos en tiempo real.
- El procesamiento manual de las formas de onda demora la detección, localización y caracterización.




DATABASE

- **Red temporal:** 15 estaciones UGL-4G 3C.
- **Evento:** réplicas del terremoto Yangbi MS 6.4 (21 de mayo de 2021).
- **Periodo de monitoreo:** del 27 de mayo al 17 de junio de 2021.
- **Referencia:** catálogo del China Earthquake Networks Center (CENC).



TÉCNICAS


- **4G:** transmisión de datos con retraso menor a 1 s.
- **U-Net:** detección de eventos y phase picking de ondas P y S.
- **NonLinLoc:** localización de los eventos.
- **Full-waveform matching:** determinación del mecanismo de fuente.



C.- QUAKEFLOW: A SCALABLE MACHINE-LEARNING-BASED EARTHQUAKE MONITORING WORKFLOW WITH CLOUD COMPUTING


METODOLOGÍA

1. **Flujo continuo de datos:** llega por 4G a los servidores.
2. **Detección y picado:** con IA, de ondas P y S.
3. **Localización:** de la fuente del sismo.
4. Cálculo de magnitud.
5. **Mecanismo focal:** solo si la magnitud supera un umbral.



RESULTADOS

- 7,905 réplicas detectadas y localizadas.
- 6,092 eventos en 12 días frente a 1,628 del catálogo CENC.
- 6.5 % de falsas detecciones y 5.3 % de eventos no detectados.
- **Compleitud:** M-0.1 con la red YB-RT frente a M0.2 de la red permanente.
- **Tiempo:** menos de 1 minuto por evento; el flujo completo entrega resultados en decenas de segundos a pocos minutos.
- **Hallazgo:** una zona de falla desconocida gracias a la mayor densidad de estaciones.



E.- EDGE SEISMIC PHASE PICKING: MODEL DISTILLATION FOR MULTIMODAL EARLY-WARNING SYSTEMS

PROBLEMA

Las redes sísmicas densas (MEMS, nodales, DAS) generan enormes volúmenes de datos que deben procesarse en tiempo real. Las arquitecturas centralizadas se ven limitadas por el ancho de banda, la congestión y la latencia, porque envían las formas de onda completas a servidores remotos. Los autores proponen hacer la primera inferencia cerca del sensor con un modelo compacto de Edge Machine Learning.




DATABASE

- **STEAD:** ~1.2 millones de formas de onda de más de 450,000 terremotos.
- **ETHZ:** más de 20,000 llegadas sísmicas (Suiza y región alpina).
- **TXED:** más de 20,000 eventos etiquetados y 200,000 ruidos.
- **OKLAD:** más de 1 millón de trazas; es el dataset principal para la destilación.
- **Procesamiento:** SeisBench, 100 Hz, ventanas de 30 s, partición 70/15/15.



TÉCNICAS



- **Knowledge Distillation:** transfiere el conocimiento de un modelo grande a uno compacto.
- **PhaseNet (Teacher) y XiaoNet (Student),** este último diseñado para dispositivos edge.
- **Encoder-decoder con depthwise separable convolutions:** menos parámetros y operaciones.
- **PyTorch, ONNX y TensorRT:** para comparar modalidades de inferencia.
- **MQTT:** transmite solo los metadatos del dispositivo edge.



E.- EDGE SEISMIC PHASE PICKING: MODEL DISTILLATION FOR MULTIMODAL EARLY-WARNING SYSTEMS

METODOLOGÍA

1. **Datos:** cuatro datasets con SeisBench, ventanas de 30 s.
2. **Línea base:** XiaoNet entrenado desde cero.
3. **Profesor:** PhaseNet entrenado con OKLAD y congelado.
4. **Destilación:** pérdida que combina etiquetas reales y salidas del profesor, usando de 0.5 % a 100 % de los datos.
5. **Evaluación:** TPR, F1 y residuos de tiempo.
6. **Validación en hardware:** Raspberry Pi 5, Jetson Orin Nano y ESP32-S3.



RESULTADOS

- 20,208 parámetros y ~240 KB de tamaño.
- Reducción del tamaño: 92.4 % frente a PhaseNet y 94.6 % frente a EQTransformer.
- **STEAD:** TPR de 95.58 % en P y 94.67 % en S.
- **TXED y OKLAD:** 80.16 % P / 82.99 % S y 81.23 % P / 82.41 % S.
- Con destilación (100 % de OKLAD): F1 de 0.8629 en P y 0.8610 en S.
- Extra del paper: inferencia de 0.71 ms en Raspberry Pi 5, y el mensaje baja de ~27 KB a 32 bytes.



Bases de datos: 11 fuentes abiertas y heterogéneas

~55 GB

datos crudos (raw)

7.2 M

edificaciones de imágenes
satelitales

137

acelerogramas reales de Lima

9

formatos distintos



Onda sísmica

CISMID – REDACIS 211 MB

137 acelerogramas de Lima y Callao, 3
componentes a 200 Hz

5 sismos registrados

Pisco 2007 · Callao 2021 · Lima 2022 ·
Callao 2025 · Ica 2026



Suelo

Vs30 USGS 582 MB

Rigidez del suelo: 185–900 m/s

Microzonificación CISMID 6 MB

Zonas I–V e isoperiodos (PDF)

Norma E.030 0.4 KB

Z = 0.45 g, factor S, TP y TL



Edificaciones

Open Buildings v3 1.8 GB

7.2 M huellas con área

Open Buildings 2.5D 80 MB

Altura → pisos → periodo Tb

Límites INEI 2 MB

49 distritos de Lima y Callao



Validación · sismo de Turquía 2023

xBD 23 GB

8 043 escenas antes/después con daño por edificio

Maxar Open Data 819 MB

5 pares antes/después: daño real observado

ShakeMap USGS 28 MB

467 929 puntos con PGA, Sa(T) y Vs30



Tiempo real


STEAD (Stanford) 27 GB

200 000 trazas con llegada de onda P y
magnitud

Formato

HDF5 + CSV · 3 componentes · 100 Hz ·
60 s

Metodología: lakehouse medallón con Spark y Delta Lake



Modelos



Random Forest (MLlib)

Amplificación del suelo medida con las ondas de Lima



K-means

Perfiles de riesgo: $S_a(T_b)$, T_b/T_P , V_{s30} , pisos



Curvas de fragilidad

Probabilidad de daño según la demanda $S_a(T_b)$



U-Net siamesa

Daño observado en Turquía (xBD → Maxar) para validar



Tiempo real

1. Kafka: acelerograma a 100 muestras/s
2. Spark Structured Streaming (ventanas de 4 s)
3. Detector de onda P (STEAD)
4. Espectro → demanda y daño
5. Mapa actualizado en segundos

GRACIAS